

NHẬN DIỆN TỪ VỰNG NGÔN NGỮ KÝ HIỆU SỬ DỤNG MẠNG NƠ-RON ĐỒ THỊ KHÔNG GIAN - THỜI GIAN (ST-GCN)

Sinh viên thực hiện: Mai Hoàng Đức (22001565), Lê Quý Công (22001550), Đặng Xuân Minh
Hiếu (24002005)

Giảng viên hướng dẫn: TS. Cao Văn Chung

Khoa Toán - Cơ - Tin học
Trường Đại học Khoa học Tự nhiên

Hà Nội, Năm 2026

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
5. Mô hình Đề xuất: ST-GCN
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
5. Mô hình Đề xuất: ST-GCN
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển

Sự phát triển của AI và Rào cản Giao tiếp:

- Các công nghệ Nhận dạng giọng nói (Speech Recognition) và Dịch thuật (Machine Translation) đã phát triển cực kỳ mạnh mẽ.
- Tuy nhiên, các ứng dụng hỗ trợ **Ngôn ngữ ký hiệu (Sign Language)** - phương tiện giao tiếp duy nhất của người khiếm thính - vẫn còn rất hạn chế.
- Điều này tạo ra một rào cản vô hình, cô lập người khiếm thính khỏi sự tiếp cận thông tin của xã hội số.

Ngôn ngữ ký hiệu là một hệ thống Đa phương thức (Multimodal Language):

- Không phải là việc ghép từng chữ cái (Fingerspelling).
- Cấu thành từ 4 yếu tố chính:
 - ① Sự di chuyển của hai bàn tay.
 - ② Định hướng của lòng bàn tay.
 - ③ Tư thế của cánh tay (Pose/Arm movements).
 - ④ Biểu cảm tình tế trên khuôn mặt (Facial Expressions).
- **Thách thức:** Bài toán Word-level Sign Language Recognition (WSLR) thực chất là bài toán nhận dạng hành động video (Video Action Recognition) ở cấp độ hạt mịn (Fine-grained).

Các thách thức trong Bài toán WSLR với ảnh RGB

Trước đây, các giải pháp thường dùng hình ảnh RGB truyền thống và gặp phải **3 nhược điểm chí mạng**:

❶ Độ nhiễu môi trường (Background Clutter):

- Hình ảnh RGB chứa quá nhiều thông tin dư thừa: phong nền sau lưng, độ sáng phòng, màu sắc quần áo người biểu diễn.
- Mô hình mạng học máy (CNN) dễ bị "đánh lừa", học sai các đặc trưng nền thay vì chuyển động của tay.

② Góc máy và Tỷ lệ (Viewpoint & Scale Variations):

- Camera có thể đặt góc chéo, góc thẳng.
- Thân hình người biểu diễn to/nhỏ khác nhau, đứng xa/gần camera.
- Dữ liệu ảnh khó chuẩn hóa để đồng nhất.

③ Chi phí tính toán khổng lồ:

- Xử lý chuỗi 60 khung hình RGB ($1080 \times 1080 \times 3$ kênh) cần hàng trăm tỷ phép tính Tensor.
- Không thể triển khai lên thiết bị di động với tốc độ thời gian thực (Real-time).

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
5. Mô hình Đề xuất: ST-GCN
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển

Các phương pháp dựa trên Khung hình RGB

Hướng tiếp cận truyền thống:

- **CNN + RNN:** Trích xuất khung hình → Đưa qua ResNet/VGG (lấy đặc trưng Không gian) → Đưa qua LSTM/GRU (lấy đặc trưng Thời gian).
- **3D-CNN:** Sử dụng I3D, C3D để học trực tiếp không gian-thời gian.

Điểm yếu chí mạng:

- Số lượng tham số (Parameters) khổng lồ.
- Dễ dẫn tới **Overfitting** (Học vẹt) do tập dữ liệu ngôn ngữ ký hiệu thể giới thường rất nhỏ bé (vài chục nghìn video).

Phương pháp dựa trên Dữ liệu Khung xương (Skeleton-based)

Tại sao lại chọn Dữ liệu Khung xương?

- Chỉ theo dõi tọa độ 3D của các khớp (Joints).
- Chống nhiễu tuyệt đối với ánh sáng, màu sắc, phong nền.
- Chi phí tính toán siêu nhẹ, dễ dàng chuẩn hóa hình học (Tịnh tiến, Xoay).

Bước ngoặt ST-GCN:

- Thay vì ném dãy số (X, Y, Z) vào LSTM một cách vô tri, Yan et al. (2018) đã đề xuất mạng **ST-GCN**.
- Mô hình học bản chất vật lý của chuyển động bằng cách kết nối các điểm thành đồ thị (Khớp là đỉnh, Xương là cạnh).
- *Báo cáo này là một trong những nghiên cứu tiên phong áp dụng ST-GCN vào nhận diện toàn bộ cơ thể và ngón tay cho WSLR.*


Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
- 3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi**
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
5. Mô hình Đề xuất: ST-GCN
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển

Trích xuất Đặc trưng với MediaPipe Holistic

Pipeline MediaPipe của Google:

- Tích hợp BlazePose, Hand Tracking.
- Trích xuất tổng cộng $V = 75$ điểm:
 - 33 điểm Pose cơ thể.
 - 21 điểm Tay trái.
 - 21 điểm Tay phải.
- Biểu diễn toán học: Tại khung hình t , điểm i có tọa độ $p_{ti} = (x_{ti}, y_{ti}, z_{ti})$.
- **Tensor đầu vào:** $X \in \mathbb{R}^{3 \times T \times 75}$.



Hình: Cấu trúc liên kết Khung xương 3D MediaPipe

Mô hình Cơ sở: Long Short-Term Memory (LSTM)

Để đánh giá độ hiệu quả của ST-GCN, chúng em dùng **LSTM** làm mô hình Baseline. LSTM giải quyết triệt tiêu Gradient của RNN qua 3 cổng điều khiển Cell State C_t :

❶ **Cổng quên (Forget Gate):** Quyết định vứt bỏ thông tin cũ:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

❷ **Cổng vào (Input Gate):** Quyết định lấy thông tin mới:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

❸ **Cổng ra (Output Gate):** Xuất đầu ra ẩn:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

Sự hạn chế của LSTM trên Dữ liệu Khung xương


Vấn đề của LSTM:

- Dữ liệu đầu vào của LSTM phải là một vector 1 chiều.
- Do đó, tensor tọa độ 75 điểm (mỗi điểm 3 chiều (x, y, z)) bị **làm phẳng (Flattened)** thành một vector dài $75 \times 3 = 225$ chiều.
- **Hậu quả:** Máy tính coi tọa độ ngón tay trở và ngón chân cái là những con số bình đẳng, không hề biết chúng có liên kết vật lý hay không. Sự phụ thuộc không gian (Spatial Dependency) hoàn toàn bị phá vỡ.

Lý thuyết Mạng Nơ-ron Đồ thị (Graph Neural Network)

Mô hình hóa bằng Đồ thị $\mathcal{G} = (V, E)$:

- **Đỉnh (V):** 75 khớp trên cơ thể.
- **Cạnh (E):** Các đoạn xương thực tế nối các khớp.
- **Ma trận Kề A :** Ma trận vuông 75×75 . $A_{ij} = 1$ nếu khớp i nối khớp j , ngược lại bằng 0.



Hình: Heatmap trực quan hóa Ma trận Kề A

Phép Tích chập Không gian (Spatial Convolution)

Để thực hiện phép tích chập lan truyền tín hiệu từ ngón tay qua bàn tay, lên cổ tay... ma trận A cần được chuẩn hóa Laplacian:

$$A_{norm} = \Lambda^{-\frac{1}{2}}(A + I)\Lambda^{-\frac{1}{2}}$$

Trong đó:

- I là ma trận đơn vị (Self-loop: Đỉnh tự kết nối với chính nó).
- Λ là ma trận đường chéo bậc (Degree matrix).


Ý nghĩa: Đảm bảo khi nhân ma trận đặc trưng với A_{norm} , giá trị không bị bùng nổ (Exploding Features) tại những khớp nối với nhiều xương (như cổ tay).

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
- 4. Tiền xử lý và Phân tích Dữ liệu (EDA)**
5. Mô hình Đề xuất: ST-GCN
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển


Word-Level American Sign Language (WLASL):

- Tập hợp 100 loại ký hiệu phổ biến nhất (hello, school, drink, book...).
- Được chia tỷ lệ Train / Val / Test một cách cẩn thận để đánh giá mô hình khách quan.
- Bao gồm nhiều người biểu diễn khác nhau để mô hình học tính khái quát (Generalization).




Hình: Tỷ lệ phân chia tập Dữ liệu

Phân tích Hình thái Chuỗi Thời gian (Sequence Length)



Hình: Histogram phân bố độ dài video



Hình: Boxplot phân tích giá trị ngoại lai

Từ biểu đồ phân phối, đỉnh tập trung lớn nhất là 60 khung hình. Các video > 100 khung hình là Outliers. Do đó, quy định **chiều dài chuẩn** $T = 60$ frames.

Chuẩn hóa Hình học Không gian (Spatial Normalization)

Trái tim của Tiền xử lý, loại bỏ nhiễu tọa độ người đứng xa/gần khung hình.

- ➊ **Tịnh tiến về Gốc tọa độ:** Lấy điểm Mũi (Nose) làm tâm.

$$p'_{ti} = p_{ti} - p_{nose} \quad \forall i \in \{1, \dots, 75\}$$

- ➋ **Khoảng cách tham chiếu:** Đo khoảng cách 2 bờ vai.

$$D_{shoulder} = \|p_{ls} - p_{rs}\|_2$$

- ➌ **Chuẩn hóa Tỷ lệ (Scale Normalization):**

$$p''_{ti} = \frac{p'_{ti}}{D_{shoulder}}$$

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
- 5. Mô hình Đề xuất: ST-GCN**
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển

Cấu trúc bên trong Khối ST-GCN Block

Mỗi khối mạng ST-GCN hoạt động theo 2 pha độc lập:

① Spatial Graph Convolution (SGC) - Trích xuất Không gian:

$$X_{SGC} = \sum_k (X_{in} W_k) \cdot A_k$$

Giúp mô hình nhận diện được "hình dáng"(Shape) của bàn tay tại 1 khung hình duy nhất.

② Temporal Convolution (TCN) - Trích xuất Thời gian:

$$X_{out} = \text{Conv2D}(X_{SGC}, \text{kernel} = (9, 1))$$

Học sự biến thiên tọa độ theo thời gian. Kernel $K_t = 9$ bao quát 9 khung hình liên tiếp.

Kiến trúc Tổng thể Mô hình (Architecture Overview)

- **Đầu vào:** Lớp Batch Normalization chuẩn hóa Tensor.
- **Thân mạng:** Xếp chồng 3 Khối ST-GCN (Bộ lọc tăng dần $64 \rightarrow 128 \rightarrow 256$).
- **Temporal Pooling:** Ở khối 2 và 3, sử dụng Stride=2 để giảm một nửa số chiều dài khung hình, tăng cường tính tóm tắt đặc trưng.
- **Đầu ra:**
 - Lớp *Global Average Pooling (GAP)* nén dữ liệu thành vector 256 chiều.
 - Lớp *Fully Connected (FC)* kết hợp hàm Softmax xuất ra xác suất cho 100 lớp từ vựng.
- **Kỹ thuật chống Overfitting:** Dropout (0.5), Residual Connection.

Cấu hình Huấn luyện (Training Configurations)

- **Hàm mất mát (Loss Function):** Cross-Entropy Loss



$$\mathcal{L} = - \sum_{i=1}^C y_i \log(\hat{y}_i)$$

- **Thuật toán tối ưu (Optimizer):** AdamW.
 - Bản nâng cấp của Adam.
 - Tích hợp L2 Weight Decay giúp trọng số mạng không phình to, tránh Overfitting tốt hơn.
- **Learning Rate:** Thiết lập ban đầu $\eta = 10^{-3}$, có giảm dần (StepLR).
- **Số vòng lặp (Epochs):** 50 Epochs.

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
5. Mô hình Đề xuất: ST-GCN
- 6. Thực nghiệm và Kết quả**
7. Kết luận và Hướng Phát triển

So sánh Tốc độ Hội tụ (Training Curves)




Phân tích Biểu đồ:

- LSTM (nét đứt): Loss đi xuống rất chậm, Accuracy bị chững lại ở mức cực thấp. Dấu hiệu của Underfitting.
- ST-GCN (nét liền): Loss giảm sâu nhanh chóng, Accuracy tiệm cận hoàn hảo nhờ cấu trúc đồ thị.

Hình: So sánh Acc/Loss của LSTM và ST-GCN

Đánh giá Hiệu năng Phân loại trên Tập Test




Chỉ số vượt trội của ST-GCN:

- **Top-1 (78.6%):** Máy đoán chính xác ngay lựa chọn số 1.
- **Top-5 (91.5%):** Từ vựng thực tế nằm trong 5 dự đoán hàng đầu.
- **F1-Score (77.2%):** Trung bình điều hòa của Precision và Recall. Nhận diện đồng đều các lớp.

Hình: Chỉ số Top-1, Top-5, F1-Score


Ma trận Nhầm lẫn (Confusion Matrix)



Hình: Ma trận nhầm lẫn 100 lớp từ vựng

Đường chéo chính (Diagonal) tập trung màu sáng chứng minh mô hình dự đoán chính xác đại đa số các mẫu.

Hiệu suất trên Top 20 từ vựng phổ biến nhất



Hình: Chỉ số F1-Score của Top 20 Glosses

Những từ vựng quen thuộc (vd: hello, book) đạt mức nhận diện gần như hoàn hảo ($F1 > 0.9$).

Nội dung trình bày

1. Mở đầu
2. Tổng quan Tài liệu (Literature Review)
3. Cơ sở Lý thuyết và Kỹ thuật Cốt lõi
4. Tiền xử lý và Phân tích Dữ liệu (EDA)
5. Mô hình Đề xuất: ST-GCN
6. Thực nghiệm và Kết quả
7. Kết luận và Hướng Phát triển

- ➊ Đã xây dựng thành công **Hệ thống Nhận diện Ngôn ngữ Ký hiệu** hoàn chỉnh, giải quyết bài toán phức tạp từ video RGB → Khung xương 3D → Suy luận từ vựng.
- ➋ Kỹ thuật **Tiền xử lý Không gian (Spatial Normalization)** đảm bảo tính ổn định bất chấp góc máy và vị trí người quay.
- ➌ Chứng minh được sự **áp đảo hoàn toàn của mạng ST-GCN** so với LSTM truyền thống. Việc sử dụng Đồ thị giúp mô hình nắm bắt bản chất vật lý của chuyển động.
- ➍ Đạt kết quả xuất sắc: **Top-5 Accuracy 91.5%**, đủ điều kiện để ứng dụng vào thực tế làm bộ Gợi ý từ (Autocomplete).

- **Tích hợp Đặc trưng Khuôn mặt:** Bổ sung 468 điểm Face Mesh từ MediaPipe để học các biểu cảm (ví dụ: nhướn mày, mím môi) - vốn là ngữ điệu của ngôn ngữ ký hiệu.
- **Nhận dạng Câu liên tục (CSLR):** Nâng cấp từ Word-Level lên Continuous Sign Language Recognition, dịch cả một câu dài thay vì chỉ một từ đơn.
- **Triển khai thiết bị Edge (Mobile/IoT):** Thực hiện Lượng tử hóa mô hình (Quantization FP16/INT8) xuất ra ONNX hoặc TensorRT. Khả năng chạy Real-time trên Camera điện thoại mà không cần máy chủ GPU.

Cảm ơn Quý Thầy và các bạn đã lắng nghe!

Questions & Answers